

AI 智能体设计方案

城市路桥隧边坡结构病害智能巡检与分级评定

参赛队伍：路桥问诊局 作品名称：路桥智巡分级智能体 完成日期：2026.8.30

——基于异构视觉表征、嵌套交叉验证与对数残差后验的双分支方案——

一、需求与痛点分析

1.1 任务边界与交付目标

结构外观检测是智能巡检的重要入口。深度视觉模型能够从裂缝、锈蚀和破损图像中提取有效信息，跨结构、跨尺度与跨采集域泛化仍是本任务的主要难点。本任务覆盖数据接入、模型协同、字段决策、格式验收和提交构包，任务范围超出单一分类。输入端包含桥梁和轨道两类图像；输出端要求一图一记录、键集合固定、文件名严格对齐。

表 1 七字段输出契约

字段	任务语义	智能体处理规则
questionCategory	问题类别	仅允许“桥梁”或“轨道”，由题目文件清单路由
bridgeName	桥梁名称	桥梁按文件组映射；轨道置空
defectLocation	病害位置	缺少可验证位置监督时置空，不生成臆测文本
filename	原始文件名	与测试清单逐字匹配，禁止改名或遗漏
defectType	病害类型	桥梁采用保守策略；轨道在 22 种合法组合中分类
defectDescription	病害描述	线上消融表明空描述更稳健，故竞赛版统一置空
ratingScale(1-5)	评定等级	无可靠测试期标定时置空，避免虚假分级

这里的“置空”表示字段保留在七键骨架中，字段值写为空字符串。该定义直接关系到 JSON 结构是否合规。设计目标可归纳为四点：一是提高轨道多标签识别能力；二是维持桥梁分项的高稳定性；三是保证 1,274 行结果零缺失、零多余；四是使训练证据、结果文件和线上成绩可追溯。

1.2 数据审计与标签结构

训练数据由 2,603 条桥梁记录和 800 条轨道记录组成，测试数据由 974 条桥梁记录和 300 条轨道记录组成。轨道标签表面上是字符串，实质上由 7 个原子标签构成的有限组合类别；训练集中共出现 22 种组合，其中 69 条为多标签样本。桥梁训练记录的等级字段高度不均衡：空值 1,904 条，2 级 622 条，3 级 74 条，4 级仅 3 条。这使得直接训练五级分类器既容易向多数类坍缩，又难以对 4 级等尾部等级进行可靠标定。




图 1 样本结构与长尾

图1给出四项关键事实：桥梁规模显著大于轨道；轨道“裂缝”出现 331 次，而“钢结构锈蚀”仅 41 次；731 条轨道样本是单标签，59 条是双标签，10 条是三标签；桥梁等级横跨三个数量级。由此不能将所有字段等价地交给同一个端到端分类头，而应采用任务路由、有限组合约束与保守字段策略。

表 2 数据规模审计

数据划分	桥梁/条	轨道/条	审计结论
训练集	2,603	800	合计 3,403；轨道含 22 种合法标签组合
测试集	974	300	合计 1,274；每个文件必须恰好输出一次

数据划分	桥梁/条	轨道/条	审计结论
轨道多标签	—	69	双标签 59 条、三标签 10 条
桥梁尾部等级	3 (4 级)	—	不足以支持无约束五级泛化

1.3 核心痛点

- (1) **结构类别异构。**桥梁记录含桥名、等级等字段，轨道记录以七类病害组合为核心。若强行共享输出头，桥梁多数类会压制轨道尾部类，且字段语义会相互污染。
- (2) **多标签样本稀少。**轨道中 91.4% 为单标签，只有 1.2% 为三标签。对 7 个原子分别阈值化会产生训练中未出现的非法组合；若只做组合分类，又可能忽略原子之间的共享视觉证据。
- (3) **数据量与模型容量不匹配。**轨道仅 800 条，直接深度微调整个大模型容易过拟合。需要先利用冻结基础表征形成低方差锚点，再对少量高层参数做受控任务对齐。
- (4) **验证泄漏与选择偏差。**同源、同文件组图像存在相关性；若样本随机打散，近似图可能同时进入训练折与验证折。在同一层交叉验证上选超参数并报告性能还会产生乐观偏差，因此需要将超参数选择与外层性能评估分离。
- (5) **线上目标与离线指标不完全一致。**平台公开总分及两个分项，但未公开逐行真值。桥梁与轨道分项权重分别为 0.7645 和 0.2355，任何轨道提分都必须避免破坏占比更高的桥梁分支。
- (6) **高分不等于安全部署。**竞赛版桥梁分支最终采用全“完好”的保守输出，在线桥梁分项为 91%。这说明评测数据与字段策略之间存在强先验，但不能据此推断真实道路桥梁均完好。因此，工程部署必须保留人工复核和不确定性拒识。

1.4 设计准则与验收指标

系统遵循“先契约、后模型；先 OOF、后测试；先稳定锚点、后小步修正；先可回退、后扩展”的准则。表3将每项目标绑定到可执行验收项，避免只给概念架构而没有检验闭环。

表 3 目标与验收标准

设计目标	验收指标	对应证据
识别有效	OOF micro-F1、Dice、Exact 与 Macro-F1 同时报告	800 条轨道 OOF 预测
选择无泄漏	外层固定折评估、内层独立选 C ，测试集不参与选择	外层 5 折各 160 条、内层 4 折验证

设计目标	验收指标	对应证据
后验稳健	$\alpha \pm 5\%$ 改动集合不变	三个权重下均改动 9 条测试样本
结果完整	1,274 行、七键、文件唯一、类别合法	独立审计脚本全部 PASS
线上有效	总分与两分项有截图凭证	85.49、91%、67%
可安全回退	最终后验异常时恢复概率锚点	锚点矩阵与包哈希均冻结

二、智能体总体架构设计

2.1 五层双分支闭环

智能体以状态机统一组织任务解析、数据治理、模型协同、规则约束和证据交付。总体架构如图2所示：第一层把官方要求转为桥梁、轨道和全量三类子任务；第二层建立三视图与异构编码器表征；第三层以五折嵌套验证选择模型并完成浅微调与概率后验；第四层把双分支结果装配为七字段 JSON；第五层通过 OOF、Bootstrap、线上成绩和哈希完成闭环。

2.2 桥梁—轨道任务路由

设输入样本为 $x_i = (I_i, f_i, q_i)$ ，其中 I_i 为图像， f_i 为文件名， $q_i \in \{\text{桥梁}, \text{轨道}\}$ 为题目类别。路由器 R 不使用视觉模型猜测题类，而直接读取官方清单：

$$R(x_i) = \begin{cases} \mathcal{B}(I_i, f_i), & q_i = \text{桥梁}, \\ \mathcal{T}(I_i, f_i), & q_i = \text{轨道}, \end{cases} \quad (1)$$

其中 $\mathcal{B}$ 为桥梁保守分支， $\mathcal{T}$ 为轨道视觉组合分支。双分支最后均进入契约装配器 A ，得到七字段记录 $y_i = A(R(x_i))$ 。

表 4 双分支职责

分支	主要输入	决策机制	最终测试输出
桥梁	文件名、桥名映射、历史消融	保护高权重分项，避免不可靠病害与等级猜测	974 条；桥名保留，类型“完好”
轨道	图像、五编码器特征、微调特征	22 类组合 LR 与 log 残差后验	300 条；9 种预测组合

分支	主要输入	决策机制	最终测试输出
装配	两分支记录、官方文件清单	同序、同键、同文件，一次性全量校验	1,274 条 JSON 记录

桥梁分支是比赛评分约束下的受控策略，其结论不适用于工程安全鉴定。训练集等级极端长尾，测试真值不可见；字段敏感性审计表明，桥名映射与病害类型必须稳定保留，描述和等级缺少足够监督支撑。当前最高提交包因此对桥名做确定映射、对病害类型采用保守输出，并将描述和等级置空。工程版应在新增有代表性的分级标注后重新训练，并以“不确定—转人工”替代全完好先验。

2.3 智能体状态机与工具链

智能体内部维护 $\{\text{INIT}, \text{AUDITED}, \text{TRAINED}, \text{FROZEN}, \text{PACKED}, \text{VERIFIED}\}$ 六个状态。只有当前状态的断言全部通过，才允许进入下一状态：

$$s_{t+1} = \delta(s_t, e_t), \quad \delta(s_t, e_t) = \text{STOP} \quad \text{if } \neg \text{Check}(e_t). \quad (2)$$

其中 e_t 包含行数、形状、类别集合、概率有限性、文件哈希和指标日志。训练任务由独立 Python 脚本实现，统计图从审计 CSV 生成，架构图保留 draw.io 源文件；因此论文中的数值、图形和最终包能够分别追溯到数据层、计算层和呈现层。

2.4 数据治理与三视图表征

每张图像生成三个视图：原图 $v = 0$ 、水平翻转 $v = 1$ 和中心视图 $v = 2$ 。对编码器 m 得到的特征 $h_{im}^{(v)}$ 先逐视图归一化，再求和并二次归一化：

$$\tilde{h}_{im}^{(v)} = \frac{h_{im}^{(v)}}{\|h_{im}^{(v)}\|_2}, \quad z_{im} = \frac{\sum_{v=0}^2 \tilde{h}_{im}^{(v)}}{\left\| \sum_{v=0}^2 \tilde{h}_{im}^{(v)} \right\|_2}. \quad (3)$$

这种处理避免某一视图或某一模型因特征范数较大而支配拼接向量。水平翻转削弱左右方向偏置，中心视图补充局部纹理，但不训练原图做离线裁切或色彩增强；模型微调时另使用随机翻转与轻量颜色扰动。

2.5 结果契约与安全回退

结果装配器首先按官方测试文件顺序创建 1,274 个空骨架，再把两分支字段写入指定索引。令 F 为测试文件名集合， G 为结果文件名多重集合，则提交前必须满足

$$|G| = |F| = 1274, \quad \text{set}(G) = F, \quad \max_{f \in F} \text{count}_G(f) = 1. \quad (4)$$




图2 智能体总体架构

对每条记录还验证键集合恰为表1中的七个键、问题类别合法、字符串可 UTF-8 编码。最终采用规范化 JSON 字节流计算

$$H = \text{SHA-256}(\text{canonical_json}(Y)). \tag{5}$$

若最终后验矩阵、稀疏改动集合或哈希任一不符，系统直接回退到已冻结的概率锚点包，测试期不执行临时调参。

三、核心模块详细设计

3.1 标签契约与组合空间模块

(1) 输入与标签字典。该模块接收 800 条轨道训练记录中的 defectType 字符串，并把可识别语义限定为七个原子：

$$\mathcal{A} = \{\text{完好, 钢结构锈蚀, 钢筋锈蚀, 裂缝, 破损, 支座锈蚀, 渗水泛碱}\}.$$

原子顺序与官方字符串保持一致，后续编码、解码和评估均复用同一字典，防止训练端与构包端出现顺序漂移。

(2) 规范化处理。原始字符串依次执行统一分隔符、去除空格、原子合法性检查、固定顺序重排和重新连接。规范化算子记为 $N(\cdot)$ ，满足 $N(N(y)) = N(y)$ ；因此“破损、支座锈蚀”等组合在重复处理后仍保持同一文本表示。

(3) 组合空间。将训练集中出现过的规范字符串去重，得到

$$\mathcal{C} = \{c_1, c_2, \dots, c_{22}\}, \quad \mathcal{C} \subseteq 2^{\mathcal{A}}.$$

模型以 22 种合法组合作为类别空间，分类头直接输出组合概率。该结构同步约束字符串合法性和样本级 Exact 目标，评估阶段再把组合展开为七维 0–1 向量计算原子指标。

表 5 轨道原子标签统计

原子标签	出现次数	识别难点
完好	103	无显著病害与弱纹理病害易混淆
钢结构锈蚀	41	样本最少，颜色与照明变化显著
钢筋锈蚀	84	常与破损共同出现
裂缝（混凝土裂缝）	331	头部类，细纹与接缝易混淆
破损	169	尺度变化大，局部缺损不明显
支座锈蚀	79	依赖构件语境，常与其他锈蚀共现

原子标签	出现次数	识别难点
渗水泛碱	72	受灯光反射、污渍与水痕干扰

(4) **输出与异常处理。**模块输出类别索引、规范组合字符串和七维原子向量。遇到未知原子、空分隔项或训练词表外组合时立即记录样本标识并停止训练；推理端仅允许 $\mathcal{C}$ 内的 argmax 结果进入装配器。图3展示七类单标签训练样本，图像只做等比缩放与白边排版。

3.2 三视图异构表征模块

(1) **输入视图。**每张轨道图像生成原图、水平翻转图和中心方形裁剪图。三种视图保留整图语境、左右方向扰动与中心局部纹理，训练集和测试集使用完全相同的视图定义。所有图像在进入各编码器前按对应预训练模型的处理器完成缩放和归一化。

(2) **并行编码器。**当前最高提交包并行调用 Qwen3-VL-Embedding-8B、SigLIP2-so400m、DINOv2-L、EVA02-L 和 ConvNeXt-V2-L。五个分支分别侧重图文语义、自监督全局结构、掩码视觉表征、局部纹理与卷积尺度稳健性，形成互补证据；编码阶段参数冻结，特征按样本标识缓存。各模型的精确权重标识和开源地址汇总于附录 C。

(3) **视图聚合。**对编码器 m 的三路输出先逐向量做 L_2 归一化，再求和并执行第二次归一化，计算规则见式(3)。五个聚合向量按固定顺序连接：

$$x_i^{\text{base}} = [z_{i,\text{Qwen}}; z_{i,\text{SigLIP}}; z_{i,\text{DINO}}; z_{i,\text{EVA}}; z_{i,\text{ConvNeXt}}] \in \mathbb{R}^{8832}. \tag{6}$$

分块归一化使每个编码器以方向信息参与拼接，减少维度和数值尺度差异造成的单支配效应。

表 6 异构编码器配置

编码器	维度	表征类型	当前职责
Qwen3-VL-Embedding-8B	4,096	图文语义	提供官方高层语义特征
SigLIP2-so400m	1,152	图文语义	表征裂缝、锈蚀与构件语境
DINOv2-L	1,024	自监督视觉	补充形状、局部结构与纹理
EVA02-L	1,024	掩码视觉	提供困难样本的互补视觉方向
ConvNeXt-V2-L	1,536	卷积视觉	强化局部纹理与尺度稳健性
合计	8,832	拼接特征	各分量独立归一化后定序拼接

(4) **制品形状。**训练特征矩阵和测试特征矩阵的形状分别为 800×8832 与 300×8832 。缓存文件同时保存样本 stem、特征维度、编码器标签和生成顺序；读取时先核对 stem



每类取一个单标签训练样本；仅等比缩放并留白，未裁剪、未增强

图3 七类训练样本

集合和哈希，再允许拼接。

(5) **模块输出**。输出 x_i^{base} 作为冻结基础表征，并向浅层任务适配模块提供稳定锚点。图4上半部分给出三视图扇出、五编码器并行和 8,832 维汇流过程，下半部分展示当前使用的任务适配支路。




图4 异构表征与浅层适配架构

3.3 嵌套验证与组合决策模块

(1) **模型输入与输出**。分类器接收 8,832 维冻结表征或 9,984 维任务表征，以 22 种合法组合为类别。设 $K = 22$ ，权重矩阵 $W \in \mathbb{R}^{K \times d}$ ，类别概率为

$$p(y_i = k | x_i) = \frac{\exp(w_k^\top x_i + b_k)}{\sum_{j=1}^K \exp(w_j^\top x_i + b_j)}. \quad (7)$$

(2) **正则化决策头**。小样本高维场景采用带 L_2 正则的多项逻辑回归，优化目标为

$$\min_{W, b} - \sum_{i=1}^n \log p(y_i | x_i) + \frac{1}{2C} \|W\|_F^2. \quad (8)$$

线性头只学习各表征方向与组合类别的关系，避免在 800 条样本上叠加高容量解码器。

(3) **嵌套选参**。外层使用固定五折，每折 160 条；每个外层训练集内部再执行 4 折验证，从 $C \in \{0.5, 1, 2, 5, 20\}$ 中选择 $\hat{C}_{-k}$ 。无泄漏估计写为

$$\widehat{M}_{\text{nested}} = \frac{1}{5} \sum_{k=1}^5 M(D_k, \mathcal{A}(D_{-k}; \hat{C}_{-k})), \quad (9)$$

其中外层验证折 D_k 不参与对应的正则系数选择。当前生产头在全量 800 条训练数据上按已锁定流程拟合，正则系数为 $C = 20$ 。

(4) **相关性控制**。项目另建立 777 个近重复文件组，检查固定五折中的相关图分布，并以组为单位执行 Bootstrap。该诊断用于量化相邻场景相关性对统计读数的影响；模型选择仍只读取训练折和 OOF 证据，测试标签全程不可见。

(5) **输出与验收**。模块输出每条样本的 22 维概率、top-1 组合、折编号和 OOF 标记。五折必须各覆盖 160 条且合计恰为 800 条，概率行和误差不得超过数值容差，组合索引必须与规范词表逐项一致。图5将外层留出、内层选参、OOF 验收与全量生产头分成隔离路径，橙色 D_k 只进入预测算子，不参与正则系数选择或模型拟合。




图 5 嵌套验证与组合决策架构

3.4 SigLIP2 浅层任务适配模块

(1) **输入与基座。**当前方案采用 vit_so400m_patch14_siglip_378.webli，输入统一缩放为 378 × 378。预训练权重负责提供通用视觉语义，22 类组合监督用于轨道病害任务对齐。

(2) **可训练区域。**模型前置 Transformer 块保持冻结，仅最后 4 个块、归一化层和 22 类分类头参与梯度更新。该划分保留预训练表示的稳定部分，同时允许高层语义适配裂缝、锈蚀、破损和构件语境。

(3) **优化配置。**训练 3 轮，批量大小 8；优化器采用 AdamW，骨干学习率 3×10^{-5} ，归一化层和分类头学习率 10^{-3} ，权重衰减 0.05，并使用余弦退火、随机水平翻转、轻量颜色扰动和 0.1 标签平滑。随机种子与样本顺序写入运行记录。

(4) **折外训练。**OOF 阶段每个模型只使用对应的 640 条训练样本更新参数，再为 160 条留出样本提取特征；五折拼接后覆盖全部 800 条。生产阶段沿用同一超参数，以 800 条训练样本拟合全量模型，再为 300 条测试图像提取表征。

(5) **特征输出。**分类头前的 pre-logits 为 1,152 维，经 L_2 归一化后与冻结表征拼接：

$$x_i^{\text{task}} = [x_i^{\text{base}}; z_i^{\text{FT-SigLIP}}] \in \mathbb{R}^{9984}. \tag{10}$$

式(10)得到当前概率锚点的输入。图6进一步展开受控解冻边界、22 类监督头、折外特征生成和生产表征拼接，其输入输出维度与图4下半部分保持一致。

表 7 浅层适配锁定参数

参数	锁定值	模块作用
输入与 patch	378 × 378, patch14	统一视觉标记尺度
解冻范围	最后 4 块 +norm+head	受控任务对齐
轮数与批量	3 轮, batch 8	控制小样本更新强度
骨干/头学习率	$3 \times 10^{-5}/10^{-3}$	分层优化预训练块与任务头
优化与衰减	AdamW, wd 0.05	抑制权重漂移
数据扰动	随机翻转、轻量 ColorJitter	增强方向和光照稳健性
损失	CE22, 平滑 0.1	降低组合概率过度自信
输出	1,152 维 pre-logits	拼接为 9,984 维任务表征




图 6 SigLIP2 浅层任务适配架构

3.5 EVA 对数残差后验模块

(1) **三组概率输入**。全量 SigLIP2 任务适配模型产生 300×22 概率锚点 p^A 。五折配对基准 p_f^B 由 9,984 维任务表征和 $C = 20$ 逻辑回归生成；五折 EVA 候选 p_f^E 在同一输入上追加 1,024 维任务适配 EVA02-L 特征，总维度 11,008。EVA 支路使用 448 像素输入，训练最后 4 块、fc_norm 和 22 类头；两臂共享折划分与分类头配置，差异集中在新增 EVA 表征。

(2) **折内相对证据**。先把两臂概率裁剪到 $[\varepsilon, 1]$ 并进入 $\log$ 空间，再计算候选相对基准的折内变化：

$$r_i = \frac{1}{5} \sum_{f=1}^5 [\log(\text{clip}(p_{if}^E, \varepsilon, 1)) - \log(\text{clip}(p_{if}^B, \varepsilon, 1))], \quad (11)$$

其中 $\varepsilon = 10^{-12}$ 保证有限数值。配对相减消除两臂共同的样本难度和概率尺度，五折平均保留方向一致的相对证据。

(3) **锚点收缩更新**。最终概率为

$$q_i = \text{softmax}(\log(\text{clip}(p_i^A, \varepsilon, 1)) + \alpha r_i), \quad \alpha = 0.25. \quad (12)$$

Softmax 把更新结果恢复到 22 维概率单纯形； $\alpha = 0.25$ 限制 EVA 证据的作用幅度，使完整 SigLIP2 锚点保持主导。


(4) **合法组合解码**。概率输出按

$$\hat{c}_i = \arg \max_{c \in C} q_{ic}, \quad |C| = 22 \quad (13)$$

转换为规范组合字符串。类别索引、字符串词表和七维原子向量使用同一映射表，推理后无需阈值搜索。

(5) **固定安全门**。测试端相对锚点固定改变 9 行，每行新旧类别的 EVA 相对方向至少获得 4/5 折支持； $\alpha \in \{0.2375, 0.25, 0.2625\}$ 时改动集合完全一致。任何断言失败都会停止

构包并保留原锚点包。后验阶段只读取冻结概率，日志记录 `test_images_accessed=0`。图7给出两条概率路径、 $\log$ 残差汇流、合法组合解码和并行断言。



3.6 双分支装配与审计模块

- (1) 桥梁分支。装配器按官方文件清单读取 974 条桥梁记录，以文件组映射恢复桥名，病害类型写入当前冻结的保守结果，位置、描述和等级按字段策略写入空字符串。该分支不调用轨道概率矩阵。
- (2) 轨道分支。300 条轨道记录依次读取概率锚点、五折配对概率和类别词表，执行式(11)–(13)，随后调用 $N(\cdot)$ 规范化组合字符串。除 `defectType` 外，其余字段均由固定 Schema 生成。
- (3) 同序装配。系统先按官方测试清单建立 1,274 个七字段骨架，再按题类索引写入两分支结果。每条记录保持固定键顺序，文件名逐字匹配，中文以 UTF-8 序列化。
- (4) 硬断言。概率、折覆盖、改动范围、行数、键集合、文件集合和压缩包边界均在写包前检查，规则见表8。

表 8 构包硬断言

检查项	判定条件	失败动作
概率矩阵	形状为 300×22 ，全部有限、行和为 1	立即停止
折完整性	五折各 160 条 OOF，索引覆盖且互斥	立即停止
改动集合	后验相对锚点仅改 9 行，支持折数至少 4/5	保留锚点包
结果行数	桥梁 974、轨道 300、总计 1,274	禁止构包
键与文件	每行七键；文件集合与测试清单完全一致	禁止构包

检查项	判定条件	失败动作
压缩包	可解压、结果可解析、SHA-256 与清单一致	重新打包

(5) **审计输出**。模块生成 result.json、行级 diff、概率清单、运行摘要和 SHA-256 记录。后验与构包实测耗时 0.44 秒；最终 9 行变化全部位于轨道 defectType，桥梁 974 行和其他六个字段逐字节保持。完成标记只有在独立验证脚本复算公式、检查 tar 边界并得到 PASS 后写入。

四、创新点设计

4.1 面向最高提交包的技术路线演进

当前最高提交包的技术路线体现了由“字段可交付”向“表征可迁移、决策可约束、后验可校准、制品可验收”的能力演进。图8从左到右给出五个相互依赖的技术阶段：先把官方要求固化为双分支七字段契约，再建立多视图异构冻结表征；随后用浅层任务适配完成病害语义对齐，以 22 种训练可见组合限制解码空间；最后叠加 EVA 五折对数残差，并通过确定性装配与哈希验收输出提交包。



图 8 最高提交包技术路线

五个阶段分别产出双分支数据骨架、8,832 维冻结特征、9,984 维概率锚点、轨道合法病害组合和 1,274 行提交制品。阶段间以显式矩阵形状、类别词表和 SHA-256 衔接，任何接口断言失败都会阻断后续构包。

4.2 异构表征的边际互补机制

传统集成常把多个模型预测直接平均，难以判断收益来源。本方案把各编码器定义为独立冻结特征块，并在统一嵌套 CV 口径下评估边际互补。五编码器总维度达到 8,832，每块先单独归一化，最终分类器保持为带 L_2 正则的线性模型；主要计算量集中在离线表征提取，分类头维持低容量。

学习曲线给出了该机制的适用边界：训练样本少于约 400 条时，高维拼接的优势不稳定；数据达到 440 条后，互补表征才持续产生正向信号。因此，编码器是否进入当前

架构由样本规模、折间一致性和边际互补共同决定。

4.3 稳定锚点上的 log 残差校准

当前最高提交包以浅层任务适配输出为概率锚点，并把 EVA 五折候选相对配对基准的变化转换为 log 残差。该机制具有三项性质：

- 1. **锚点保持**： $\alpha = 0$ 时严格恢复浅层任务适配模型；
- 2. **方向聚合**：五折共同支持的类别才得到稳定修正；
- 3. **改动稀疏**：300 条测试轨道仅 9 条改变，桥梁和非类型字段不变。

与“把候选概率直接平均”相比，对数空间相减先消除了候选与其基准的固有标度差异，再把相对证据迁移到概率锚点。这是一个面向小样本、高风险提交场景的低扰动后验更新策略。

4.4 组合合法性与指标对齐

七个原子独立训练看似更自然，但会带来阈值搜索、非法组合和 Exact 崩落。系统把 22 种规范组合作为基本类别，训练时优化组合交叉熵，推理时只输出合法字符串；评估时再把组合展开计算原子 micro-F1、样本 Dice 和 Macro-F1。这样既对齐官方字符串输出，又保留原子层诊断能力。

4.5 创新点汇总

表 9 创新点及价值

创新层面	具体设计	可验证价值
体系创新	桥梁保守分支、轨道视觉分支与契约装配器解耦	避免高权重桥梁字段被轨道模型扰动
表征创新	图文、自监督与卷积五编码器互补融合	8,832 维表征的嵌套 CV 为 0.6053
训练创新	只解冻 SigLIP2 最后 4 块并追加 pre-logits	9,984 维锚点表征的嵌套 CV 为 0.6275
后验创新	概率锚点叠加 EVA 五折 log 残差	仅修正 9 条轨道类型，其他字段保持不变
验证创新	分组诊断、嵌套 CV、20,000 次组 Bootstrap 与线上互证	同时报告点估计与区间

创新层面	具体设计	可验证价值
工程创新	行级 diff、七键断言、哈希冻结与锚点回退	构包 0.44 秒，制品可追溯

五、效果评估

5.1 评估指标

令 $Y_{ia}, \hat{Y}_{ia} \in \{0, 1\}$ 表示第 i 个样本在原子 a 上的真值和预测。原子 micro-F1 为

$$F_{1,\text{micro}} = \frac{2 \sum_{i,a} Y_{ia} \hat{Y}_{ia}}{2 \sum_{i,a} Y_{ia} \hat{Y}_{ia} + \sum_{i,a} (1 - Y_{ia}) \hat{Y}_{ia} + \sum_{i,a} Y_{ia} (1 - \hat{Y}_{ia})}. \quad (14)$$

样本 Dice 与组合 Exact 分别为

$$\text{Dice} = \frac{1}{n} \sum_{i=1}^n \frac{2|Y_i \cap \hat{Y}_i|}{|Y_i| + |\hat{Y}_i|}, \quad \text{Exact} = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(Y_i = \hat{Y}_i). \quad (15)$$

Macro-F1 则先逐原子计算 F1 再等权平均，用于观察尾部类是否被头部裂缝类掩盖。四个指标共同报告，防止只优化某一统计量。

5.2 离线评估结果

图9从同口径消融、样本规模曲线、五折配对和实测耗时四个角度核验当前表征与浅层适配配置。五编码器在样本规模充分时提供互补方向，后四块 3 轮适配在五折上形成稳定任务特征；该图用于解释当前架构的证据边界，模块实现仍以第三章的锁定参数为准。

当前最高提交包的后验层在 800 条 OOF 样本上相对概率锚点改变 19 条，其中纠正 12 条、引入错误 2 条、错误类别间迁移 5 条；最终 Exact 正确数为 504。四项指标及七类原子变化如图10所示。

表 10 轨道 OOF 指标

指标	概率锚点	最终后验	校准效应/pp
原子 micro-F1	0.66114	0.67259	+1.145
样本 Dice	0.66917	0.68167	+1.250
组合 Exact	0.61750	0.63000	+1.250
宏平均原子 F1	0.59970	0.60959	+0.990




图9 表征与适配证据




图10 后验校准验证

七个原子中没有 F1 下降，破损提升最大，为 3.621 个百分点；钢结构锈蚀保持不变；其余五类小幅上升。因为候选权重是在同一批 OOF 实验中受到启发，点估计仍可能乐观，故进一步以 777 个文件组为抽样单位进行 20,000 次 Bootstrap 复算。本任务每次按文件组有放回重采样并重新计算增益，从而保留同组样本相关性并得到经验分布。

设第 b 次重采样得到的增益为 $\Delta^{(b)}$ ，区间取 2.5% 与 97.5% 分位数：

$$CI_{95\%} = [Q_{0.025}\{\Delta^{(b)}\}, Q_{0.975}\{\Delta^{(b)}\}] = [0.314, 2.046] \text{ pp.} \quad (16)$$

20,000 次中 99.61% 的 $\Delta^{(b)} > 0$ 。该区间支持后验具有正向信号，但仍不替代新的独立数据确认。

5.3 线上评估结果

当前最高提交包于 2026 年 8 月 29 日 12:02:51 完成评测，平台显示总分 85.49。桥梁分项 9.12/10 (91%)、权重 0.7645；轨道分项 0.67/1 (67%)、权重 0.2355。按平台展示口径，综合分可写为

$$S \approx 100 (0.7645 \times 0.912 + 0.2355 \times 0.67) = 85.50, \quad (17)$$

与 85.49 的 0.01 差异来自页面分项四舍五入。



图 11 线上评分凭证

图中仅裁去文件列表与鼠标提示区域，综合得分、两项评分细则及权重均保持平台原始像素；未裁切原图继续作为哈希核验制品保存。

表 11 线上成绩核验

项目	当前最高包	核验依据
线上总分	85.49	平台评分详情与截图
桥梁分项	9.12/10 (91%)	权重 0.7645，共 974 条结果
轨道分项	0.67/1 (67%)	权重 0.2355，共 300 条结果
包内总行数	1,274	七键、文件集合与唯一性全部通过
后验影响范围	9 条轨道类型	桥梁与其余六字段逐字节保持
压缩包大小	24,328 B	解压复核与 SHA-256 一致

线上结果仅用于确认当前冻结技术路线在隐藏测试集上的整体有效性。一次提交只提供单个隐藏测试点，不能据此估计长期波动；因此本文将其与 OOF 四指标、组 Bootstrap 和 α 灵敏度共同使用，并将适用范围限定在本次评测数据分布内。

5.4 测试集推理耗时

当前最高提交包的正式运行摘要记录：在冻结模型制品已经加载的执行态下，对测试集 300 条轨道概率执行 EVA 对数残差融合与 22 类合法组合解码，同时装配 974 条桥梁确定性结果，完成全部 1,274 条七字段记录校验、JSON 序列化和 tar.gz 构包，单次实测总耗时为**0.44 秒**。折合每条 0.35 毫秒，吞吐量约 2,893.08 条/秒。该数值只对应当前最高包的测试集决策推理与交付闭环，所有 OOF 训练、参数选择和微调耗时均已排除。

计时输入为已冻结的测试概率制品，运行摘要同时记录 `test_images_accessed=0`。因此，0.44 秒不代表五个视觉编码器从原始图片重新前向的耗时；项目没有保存同一硬件、同一批量条件下的完整原图端到端计时，本文不对此进行外推。图12和表12明确给出本次可审计的计时范围。

表 12 当前最高提交包测试集推理实测

任务	耗时	说明
测试集决策推理与构包	0.44 s	300 条轨道后验解码、974 条桥梁装配、1,274 条校验及构包
平均单条延迟	0.35 ms	以 1,274 条测试记录均摊
测试集处理吞吐	2,893.08 条/s	同一次 0.44 秒运行折算
视觉骨干原图前向	未纳入	计时输入为冻结概率制品，运行摘要记录访问测试图像数为 0




图 12 测试集推理耗时与制品校验

5.5 格式、完整性与可复现性

当前最高提交包大小 24,328 字节，SHA-256 为

5d0f1187e3e834a731093f5d05041b581a45151e8e2c359faf81f10339711ec0。

独立审计确认：桥梁 974 条、轨道 300 条；所有文件名唯一；每条均含七个规定键；轨道输出全部属于 22 种训练可见组合，规范化 JSON 可重复序列化，重新解压后的内容与冻结清单一致。后验层相对概率锚点只影响 9 条轨道 defectType，桥梁结果及其他六个字段保持不变。

六、部署、局限与结论

6.1 工程部署方案

竞赛版可部署为“离线训练服务 + 冻结特征仓 + 轻量推理编排器 + 验收器”四部分。离线训练服务周期性更新五编码器特征和浅微调模型；冻结特征仓按文件哈希保存向量、概率与折索引；推理编排器执行双分支路由和式(12)；验收器负责七键、行数、标签、哈希与回退。实际市政业务中还应增加三类能力：

- **拒识机制**：当最大概率、折间一致性或图像质量低于阈值时标记“需复核”，不得自动判为完好；
- **时序聚合**：对同一构件多时点图像进行轨迹级去重和病害演化判断；
- **闭环学习**：将人工复核结果写回样本库，按结构类型、等级和采集域分层再训练。

6.2 风险与适用边界

表 13 局限与缓解措施

局限	影响	缓解措施
桥梁全完好先验	适合本次评分，不代表真实结构安全状态	工程版必须训练桥梁病害和等级模型并人工复核
后验形式受 OOF 启发	Bootstrap 仍可能低估研究者自由度	新批次锁定公式盲测；保留概率锚点回退
仅一次隐藏测试	不能估计跨城市、跨设备长期方差	多域外部验证和时间切分
历史 EVA 候选权重已清理	可从锁定概率重放最终后验，暂不能从原权重完全复训	后续建立权重登记表和对象存储
最高分包代码目录沿用锚点阶段结构	包内未完整嵌入后验脚本	正式工程包加入 <code>run_all.py</code> 与独立验证脚本
轨道组合限于 22 类	新型组合会被映射到最近的已知组合	增加开放集拒识与原子辅助头
图像级输出	不能提供像素级病害面积与构件几何量	后续接入检测/分割与测量标定

尤其需要强调，当前最高提交包具备**概率层级可重放性**：锁定的概率锚点、五折基准/候选概率、公式、 α 和结果哈希均可复算；但由于历史候选检查点在项目清理中删除，不具备完整的**原始权重层级可重训练性**。本文不把前者包装成后者。

6.3 模型评价

优点：（1）任务路由与字段契约清晰，适配桥梁和轨道异构标签；（2）模型选择使用固定五折嵌套 CV，并另设文件组相关性诊断，较单层随机验证更稳健；（3）异构编码器、浅层任务适配和后验残差构成清晰的能力链；（4）后验影响范围仅 9 条轨道类型，风险和回退边界明确；（5）提交包、统计图、draw.io 和 CSV 源数据均可追溯。

不足：（1）桥梁竞赛策略依赖数据先验，不能直接用于安全鉴定；（2）轨道多标签仍受 800 条样本规模限制，尾部钢结构锈蚀 F1 校准效应为 0；（3）概率后验的独立确认次数有限；（4）五编码器离线制品约 27 MB，微调权重约 1.6 GB，边缘端部署需蒸馏或量化。

6.4 结论

本文完成了一套面向城市路桥隧边坡结构病害的双分支智能体设计方案。系统以七字段输出契约为入口，以五类异构视觉特征为基础，以 SigLIP2 浅层微调实现任务对

齐，并用 EVA 五折 log 残差在稳定概率锚点上进行低扰动修正。离线四指标、20,000 次组 Bootstrap、 α 灵敏度、行级影响范围与线上成绩共同形成证据链。

当前最高提交包在桥梁分支保持稳定、后验仅影响 9 个轨道 defectType 的条件下，取得线上总分**85.49**；桥梁分项 91%，轨道分项 67%，1,274 条七字段结果全部通过审计。方案的核心价值体现在小样本建模、无泄漏验证、合法组合决策、低扰动后验和确定性交付形成了可运行、可回退、可解释的智能体闭环。

附录 A 关键参数清单

表 14 复现实验参数

参数组	锁定值	用途
视图策略	原图、水平翻转、中心视图	五编码器冻结表征
组合类别	22 类	轨道合法输出空间
外层/内层折数	5/4	无泄漏评估与选择 C
逻辑回归 C 候选	0.5、1、2、5、20	每个外折独立选择
SigLIP2 输入	378×378	浅微调与 pre-logits
解冻范围	最后 4 块 +norm+head	当前浅层适配配方
训练轮数/批量	3/8	小样本方差控制
骨干/头学习率	$3 \times 10^{-5}/10^{-3}$	分层学习率
权重衰减	0.05	AdamW 正则
标签平滑	0.1	降低过度自信
后验 ε	10^{-12}	log 概率数值稳定
后验 α	0.25	EVA 残差收缩权重
Bootstrap	20,000 次、777 组	micro-F1 增益区间

附录 B 输出示例与校验顺序

单条结果的逻辑结构如下；实际提交文件保持中文 UTF-8 与官方原始文件名：

Listing 1 七字段结果示意

```
1 {
2   "questionCategory": "轨道",
3   "bridgeName": "",
```

```

4  "defectLocation": "",
5  "filename": "<official_filename>.png",
6  "defectType": "裂缝(混凝土裂缝)",
7  "defectDescription": "",
8  "ratingScale(1-5)": ""
9  }

```

构包校验顺序为：读取官方文件清单 → 检查两分支行数 → 检查文件集合与唯一性 → 检查七键与类型 → 检查轨道组合合法性 → 规范化序列化 → 计算结果哈希 → 生成 tar.gz → 重新解压复核。任何一步失败均不生成候选提交包。

附录 C 开源模型与制品索引

表15列出当前最高提交包涉及的五个视觉基础模型。链接均指向项目实际锁定的官方组织或 `timm` 权重页，便于核对模型名称、权重文件与使用方式；模型许可证和适用条件以链接页面的最新说明为准。

表 15 当前方案相关开源模型链接

模型分支	项目锁定标识	开源地址
Qwen3-VL 嵌入	Qwen/Qwen3-VL-Embedding-8B	官方模型页
SigLIP 语义编码	timm/vit_so400m_patch14_siglip_378.webli	精确权重页
DINOv2-L	timm/vit_large_patch14_dinov2.lvd142m	精确权重页；官方仓库
EVA02-L	timm/eva02_large_patch14_448.mim_m38m_ft_in22k_in1k	精确权重页；官方仓库
ConvNeXt-V2-L	timm/convnextv2_large.fcmae_ft_in22k_in1k	精确权重页；官方仓库

可复制直链：

- Qwen3-VL: <https://huggingface.co/Qwen/Qwen3-VL-Embedding-8B>
- SigLIP: https://huggingface.co/timm/vit_so400m_patch14_siglip_378.webli
- DINOv2-L: https://huggingface.co/timm/vit_large_patch14_dinov2.lvd142m
- EVA02-L: https://huggingface.co/timm/eva02_large_patch14_448.mim_m38m_ft_in22k_in1k
- ConvNeXt-V2-L: https://huggingface.co/timm/convnextv2_large.fcmae_ft_in22k_in1k
- PyTorch Image Models: <https://github.com/huggingface/pytorch-image-models>

复现入口：审计与绘图脚本位于 `code/`，可编辑架构图和机器可读图表数据位于 `figures/`。