

城市路桥隧边坡结构病害 智能巡检与分级评定

并行推理版 - 提交设计方案

版本 contract-v1-parallel2-20260909。冻结视觉专家与Qwen权重，采用共享模型批量、CPU并发和证据合同，输出可追溯的巡检记录。

330 / 330

七字段合同通过

109.47 分钟

本轮完整入口实测

1.59 倍

固定8条评级对照加速


1 实测批量选择

实现 / 批量	8条耗时	输出核验
原SDPA / 1	408.05 秒	与原串行七字段一致
去补齐SDPA / 1	410.23 秒	与原串行七字段一致
去补齐SDPA / 2	302.15 秒	与原串行七字段一致
去补齐SDPA / 4	超出显存预算	不采用
去补齐SDPA / 8	超出显存预算	不采用
去补齐SDPA / 3	255.11 秒	与原串行七字段一致

采用批量 3、4个CPU工作线程及单份27B模型。选定配置用同一8条输入复测；该倍率只表示病害评级计算的同输入吞吐，不代表整套模型准确率或全流程加速倍数。

直接补齐的原SDPA批量2超过517.87秒仍未完成；现有FlashAttention在真实模型预热失败。两条路线均保留负面证据，未写入默认运行配置。

2 架构与专家职责



AdamW融合首选固定最终病害类型。其他专家分别提供区域、掩码、局部视觉、异常和历史参考；冻结Qwen仅对病害进行条件评级，最终七字段由确定性输出合同装配。

组件	实际职责与并发方式
区域专家	RT-DETR、SAM3、Grounding DINO并行。SAM每图复用图像编码，每份权重复用全局词表文本编码；Grounding每图复用骨干，查询独立解码。双优化器证据及版本摘要保留。
视觉特征与融合	H+蒸馏、WeMM、ConvNeXt并行；H+原始与7B异常教师并行。融合、局部与历史模型的业务职责保持。
CPU证据准备	4线程有界预取，队列深度8。每轮每份权重核验一次，逐图继续核验身份、掩码、几何和证据来源；规范索引按版本复用。
Qwen3.6-27B	单实例批量生成。注意力按各条有效长度计算，保留原SDPA算子；其他层批量计算。不同图片上下文相互隔离。
合同与持久化	4线程校验和写入，等待全部凭证完成后发布汇总；主进程通过完成事件衔接阶段，不额外等待固定轮询周期。

证据和精度边界

区域编码复用的两图全部查询对照：SAM双优化器约2.91及3.06倍，Grounding约2.31及2.22倍；候选分数、框及SAM掩码精确一致。测量时另有区域进程占用设备，只作配对优化证据。

九工具覆盖语义、局部、H+、区域、掩码、定位、异常、规范检索与历史预测。距离或相似度不解释为病害概率；历史模型参考不等于规范等级。缺少实测量与构件范围时，规范分级仍明确留缺。

没有新增训练、量化、改变提示词或覆盖模型结论。专家贡献与正式准确率仍需独立验证，接口成功不能代替精度收益。Built with PriorLabs-TabPFN。

3 七字段合同与恢复

字段	来源与条件
questionCategory	从输入结构域及已校验证据取得。
bridgeName	图像实际父目录名称，语言模型不猜测。
filename	真实文件名，保持输入顺序与身份对应。
defectType	固定AdamW融合首选，模型评级无权改写。
defectLocation	记录有依据的图像候选方位；完好或依据不足时为空。
defectDescription	依据锁定类型、位置及有效评级生成事实模板。
ratingScale(1-5)	完好为空字符串；病害为1-5字符串并有有效内部证据引用。

恢复、失败与资源回退

每个批次调用前先持久化所有样本的尝试次数，每轮至多两次。中断后保留已消耗次数；仅失败样本重试，已完成样本必须通过来源及结果重建核验。输入、证据、源码、批量或后端变化时拒绝混用恢复目录。

显存不足时逐次减半批量，最小为1，输入顺序及身份保持。非法评级、损坏凭证或不完整运行不得发布新汇总；原始失败记录和旧结果保留。结果与计时先准备，再替换并写入成对摘要凭证。

本轮223条完好、107条病害，全部通过条件评级合同。七字段合格包括明确的空字符串语义。相对历史330条结果有2行变化：1条位置、1条评级及对应描述，病害类型全部一致。

全量RT-DETR候选、SAM候选及掩码与历史缓存一致；Grounding分数一致，坐标有差异。107条病害提示词的证据内容均变化，因此报告阶段3100.83秒只作本轮观测，同输入速度结论限于冻结8条对照。

4 部署、计时与版本恢复

平台资源为16核CPU、64 GiB主存和96 GiB PPU。模型及训练参考资产留在/workspace/work，Qwen来自只读/model/Qwen3.6-27B。提交目录包含28个代码/清单文件、1份设计书和2个结果JSON，共31个普通文件。

阶段	实测秒数
区域专家等待	2231.053
特征并行第一组	632.389
特征并行第二组	469.629
全部专家装配	98.362
批量报告与评级	3114.595

本次infer_time=6568.275286197662秒。计时从Python脚本开头开始，至结果准备结束采样，包含模型加载及阶段执行；采用全新线上目录重算视觉证据和评级，复用冻结模型与训练资产。历史6194.54秒来自视觉缓存复用运行，二者不能直接计算公平的全流程加速倍数。

入口与制品

code/run --check：只核验源码与外置资产。
code/run：按清单中实测配置建立新工作目录，生成result/result.json与result/infer_time.json。
code/run --work <官方work运行目录> --resume：来源与执行配置一致时继续；仅计当前脚本调用秒数。
结果为330条七字符串字段的JSON数组；计时为仅包含infer_time的JSON对象，单位为秒。发布代码只含23个核心Python依赖、包装入口及必要清单，不包含模型、测试缓存或逐图内部轨迹。

固定版本与恢复

版本标签c4-contract-v1-parallel2-20260909。官方不可覆盖快照位于/workspace/work/c4-submission-versions/contract-v1-parallel2-20260909；源码、配置、设计书及聚合摘要在GitHub ZewenCheng/C4_fork归档。受限逐图结果只保留在官方工作区，版本清单提供恢复路径与摘要。
本轮结果SHA256：a09293f6fcb9efe043a32ed7feb8924fbcbf41d03f1dc5be38fecfae3634473。本版未取得正式评分；没有执行比赛上传或评测。